

Introducción a la ciencia de datos con R

Tarea 1

Esteban Degetau

20 de marzo de 2025

La Tarea 1 debe entregarse el jueves 27 de marzo. La entrega consiste en un archivo PDF que incluya las respuestas a las preguntas planteadas, así como el código .qmd que generó las respuestas. Para descargar el archivo .qmd, haz clic [aquí](#).

Escribe todas tus respuestas en la sección de respuestas al final de este archivo.

Escribe tu nombre en el campo `author` del YAML.

1 Preguntas

1.1 *Outliers*: Datos atípicos

Un problema común en el análisis de datos es cómo tratar con datos atípicos: aquellos valores que difieren significativamente del resto de los datos. Dos soluciones estándar son:

1. Truncar los datos: eliminando los datos atípicos
2. *Winsorizar* los datos: reemplazando los datos atípicos por un valor cercano a los valores no atípicos.

El siguiente código carga un vector llamado `ingresos`. Cada valor representa el ingreso en pesos para un hogar mexicano, de la encuesta de ingreso y gastos de los hogares (ENIGH) del 2022.

```
load("//IMSS-EDS/Users/esteban.degetau/OneDrive - INSTITUTO TECNOLOGICO AUTONOMO DE MEXICO/D
```

- a. ¿Cuál es la lognitud (length) del vector `ingresos`? (esto nos dirá el número de observaciones en los datos de la ENIGH.) ¿Cuál es la media, la mediana y la desviación estándar de `ingresos`?

b. Escribe una función para truncar un vector. Esta función debe tener dos argumentos: (1) el vector y (2) el percentil al que se truncará el vector por arriba y por abajo. La función deberá hacer lo siguiente:

- i. Calcular los percentiles inferior y superior para truncar los datos.
- ii. Crear un subconjunto del vector original, incluyendo solo las observaciones que se encuentren entre los percentiles inferior y superior.
- iii. Regresar el subconjunto.

Pista: La función `sort()` regresa un vector ordenado de menor a mayor. Para extraer múltiples elementos de un vector, puedes usar la notación `vector[1:10]` para extraer los elementos 1 al 10.

c. Escribe una función para *winsorizar* un vector. Esta función deberá tener dos argumentos: (1) el vector y (2) el percentil al que se winzorizará el vector por arriba y por abajo. La función deberá hacer lo siguiente:

- i. Calcular los percentiles inferior y superior para winzorizar los datos.
- ii. Crear un nuevo vector, reemplazando cualquier observación que sea menor al percentil inferior por el percentil inferior y cualquier observación que sea mayor al percentil superior por el percentil superior.
- iii. Regresar el vector con los valores atípicos reemplazados.

Pista: Puedes usar la notación `vector[vector < 10] <- 10` para reemplazar los valores menores a 10 por 10.

d. Crea un vector truncado del vector `ingresos`, que trunque el 1% de los datos por arriba y por abajo. ¿Cuál es la longitud, media, mediana y desviación estándar del vector truncado? Compara el histograma de `ingresos` con el histograma del vector truncado.

e. Crea un vector winzorizado del vector `ingresos`, que winzorice el 1% de los datos por arriba y por abajo. ¿Cuál es la longitud, media, mediana y desviación estándar del vector winzorizado? Compara el histograma de `ingresos` con el histograma del vector winzorizado.

f. Discute tus resultados.

1.2 Seguridad social en la población

El siguiente código carga un conjunto de datos proveniente de la ENIGH 2022 llamado `poblacion2022`. Explotaremos este conjunto de datos para explorar qué tipo de personas tienen/carecen de seguridad social en México. Adicionalmente, el código genera un diccionario de datos que queda guardado como una `tibble` llamado `dict`. Puedes consultar el diccionario de datos llamando `View(dict)`.

```
# Checar que pacman esté instalado
if (!require("pacman")) install.packages("pacman")
```

Loading required package: pacman

```
pacman::p_load(tidyverse, labelled)

load("//IMSS-EDS/Users/esteban.degetau/OneDrive - INSTITUTO TECNOLOGICO AUTONOMO DE MEXICO/D

dict <- generate_dictionary(poblacion2022)
```

La ENIGH es una encuesta representativa a nivel estatal y nacional. La variable `factor` es un factor de expansión que nos permite hablar de la muestra encuestada como si fuese la población total. Si quisiéramos saber cuántas personas considera la ENIGH que habitan en México, podríamos sumar el factor de expansión de todas las observaciones:

```
poblacion_total <- sum(poblacion2022$factor)

poblacion_total
```

[1] 128999038

- La variable `segsoc` en `poblacion2022` es una variable categórica que indica si una persona tiene o no tiene seguridad social. ¿Cuál es el porcentaje de personas en la población que tienen y no tienen seguridad social?
- ¿Qué porcentaje de hombres y mujeres tienen seguridad social? ¿Qué porcentaje de hombres y mujeres no tienen seguridad social?
- Ahora queremos saber cuál es la escolaridad promedio para las personas con y sin seguridad social. Sin embargo, la información sobre escolaridad en la tabla `poblacion2022` está codificada como `factor` en la variable `nivelaprob`. Con la siguiente tabla podemos convertir niveles escolares en años de escolaridad:

```

escolaridad <- tibble(
  nivelaprob = poblacion2022 |>
    pull(nivelaprob) |>
    unique(),
  escolaridad = c(6, 12, 9, 16, 18, 14, 1, 14, NA, 0, 20)
)

escolaridad

```

```

# A tibble: 11 x 2
  nivelaprob          escolaridad
  <fct>              <dbl>
1 Primaria              6
2 Preparatoria o bachillerato 12
3 Secundaria            9
4 Profesional          16
5 Maestría             18
6 Normal              14
7 Preescolar            1
8 Carrera técnica o comercial 14
9 <NA>                 NA
10 Ninguno              0
11 Doctorado            20

```

Usa la tabla `escolaridad` para calcular la escolaridad promedio de las personas con y sin seguridad social.

- d. Usa `ggplot2` para crear una (o varias) gráfica(s) en donde explores las siguientes preguntas:
 - ¿Cuál es el grado de cobertura de la seguridad social en México, por entidad federativa?
 - ¿Qué entidad federativa tiene la mayor y la menor cobertura de seguridad social? ¿Qué entidades están por arriba y por abajo del promedio nacional de cobertura de seguridad social?
- e. Discute tus resultados.

2 Respuestas

2.1 *Outliers*

- a. El vector `ingresos` tiene una lognitud de:

```
length(ingresos)
```

```
[1] 397182
```